



**UNIVERSIDAD AUTÓNOMA DE QUERÉTARO  
FACULTAD DE INFORMÁTICA**



**Modelos Predictivos**

**Profesor:**

**Dr. Martin Muñoz Mandujano**

**Proyecto Final  
Series Temporales**

**Jesus Gabriel Gudiño Lara**

**325675**

**Ramírez López Ana Rosa**

**325672**

DESCRIPCIÓN	NOTA
Entregado en Tiempo y Forma	
Entregado a destiempo	
Entregado sin respetar formato	
Entregado pero no cumple con instrucciones.	
COMENTARIOS ADICIONALES	

## 1. Resumen

En este proyecto se aborda el problema del pronóstico de la temperatura mínima diaria en la ciudad de Melbourne, Australia, utilizando el conjunto de datos Daily Minimum Temperatures (**1981–1990, 3650 observaciones diarias**). El objetivo principal es predecir la temperatura mínima de los próximos 7 días a partir del historial disponible y comparar el desempeño de distintos enfoques de modelado de series de tiempo.

Se realiza primero un análisis exploratorio que revela una fuerte **estacionalidad anual, ausencia de una tendencia** clara de largo plazo y una variabilidad diaria moderada. A partir de esta caracterización se construyen ventanas deslizantes de 30 días de historial para pronosticar simultáneamente los 7 días siguientes (esquema de pronóstico multistep). Sobre estas ventanas se entrena y evalúan cuatro enfoques: una **regresión armónica** con términos de **Fourier**, un modelo de **XGBoost**, una red neuronal **LSTM** y un **ensamble híbrido** que combina la componente armónica con XGBoost.

Los modelos se evalúan principalmente mediante las métricas **RMSE** y **MAE** sobre un conjunto de prueba que corresponde al 20 % final de la serie. Los resultados muestran que, aunque los modelos

individuales logran errores en el rango de **2.5–2.7 °C de RMSE**, el **ensamble Harmonic + XGBoost reduce el error** a aproximadamente 2.22 °C de RMSE y **1.75 °C de MAE**, ofreciendo pronósticos físicamente coherentes y estadísticamente más robustos. Se concluye que, para este tipo de serie fuertemente estacional y con datos limitados, la combinación de un modelo determinista estacional con un algoritmo de boosting resulta más efectiva que el uso aislado de redes profundas.

## 2. Introducción y Objetivo

2.1. Contexto: El pronóstico de la temperatura es un componente clave en numerosas aplicaciones reales, como la planificación de la demanda energética, la agricultura, la salud pública y la gestión de infraestructuras. En particular, la temperatura mínima diaria influye en la formación de heladas, el consumo de calefacción, la calidad del aire y la carga térmica de las ciudades. Desde el punto de vista de las series de tiempo, la temperatura es un **fenómeno fuertemente condicionado por la estacionalidad anual, asociada al ciclo astronómico de la Tierra** y a la posición geográfica de la región de estudio.

En este trabajo se analiza la temperatura mínima diaria registrada en **Melbourne, Australia, a lo largo de diez años continuos (1981–1990)**. Al tratarse de una

ciudad del hemisferio sur, los máximos y mínimos térmicos se organizan en torno al verano e invierno australes, lo que se traduce en un patrón cíclico marcado. Esto hace especialmente interesante estudiar hasta qué punto es necesario recurrir a modelos complejos de aprendizaje profundo, o si un **modelado estacional bien diseñado** puede competir o incluso superar a enfoques más sofisticados.

## 2.2. Planteamiento del problema

Se dispone de una serie de tiempo univariante con la temperatura mínima diaria (en °C), indicada por las columnas Date y Temp. El problema concreto a resolver es: pronosticar las temperaturas mínimas de los próximos 7 días a partir de los valores observados en los días previos. Este proyecto busca responder a la siguiente pregunta central:

**¿Es realmente necesario utilizar modelos de deep learning (como LSTM) para pronosticar la temperatura mínima diaria de Melbourne, o un enfoque basado en estacionalidad determinista (Fourier) y modelos de machine learning clásicos (como XGBoost) puede ofrecer un desempeño igual o mejor?**

Para ello, se diseña un experimento comparativo en el que se entrena y evalúan diferentes modelos sobre la misma partición de entrenamiento/prueba y bajo el mismo esquema de ventanas temporales.

**3. Objetivo general:** Desarrollar y evaluar un sistema de pronóstico de series de tiempo que, a partir de la temperatura mínima diaria histórica de Melbourne, sea capaz de predecir la temperatura mínima de los próximos 7 días, comparando el desempeño de modelos estadísticos, de machine learning y de deep learning, y seleccionando un modelo final robusto para pronóstico fuera de muestra.

## 3.4. Objetivos específicos

- **Analizar la serie de tiempo mediante estadísticas descriptivas, visualizaciones, medias móviles, ACF/PACF** y descomposición estacional, identificando tendencia, estacionalidad y posibles outliers.
- **Preprocesar los datos** corrigiendo el formato de las columnas, manejando valores faltantes y definiendo una división train/test que respete el orden temporal.
- **Construir un conjunto de características basado en ventanas móviles** de 30 días de historial para un **horizonte de pronóstico de 7 días** (esquema multistep).
- **Entrenar al menos un modelo basado** en redes neuronales LSTM y compararlo con:
  - un modelo de **XGBoost**,
  - una **regresión armónica** con términos de **Fourier**,
  - y un **ensamble híbrido** que combine la componente estacional determinista con el modelo de boosting.

- Evaluar el desempeño de cada modelo mediante métricas como MAE, RMSE y MAPE en el conjunto de prueba, así como mediante gráficos de valores reales vs. pronosticados.
- Generar un pronóstico futuro para la primera semana de enero de 1991 y discutir la plausibilidad física de los resultados, así como las ventajas y limitaciones de cada enfoque.

## 4. Descripción del dataset y de la serie de tiempo

### 4.1. Origen y estructura del conjunto de datos

Para este proyecto se utilizó el conjunto de datos conocido como **Daily Minimum Temperatures in Melbourne**, que contiene registros históricos de la **temperatura mínima diaria** de la ciudad de Melbourne, Australia, durante diez años consecutivos.

El archivo proporcionado (1\_Daily\_minimum\_temps.xlsx) incluye originalmente una sola columna de texto con el formato Date,Temp, donde la fecha y la temperatura se encuentran separadas por una coma. A partir de esta columna se generaron dos variables explícitas:

- **Date**: fecha de la observación diaria.
- **Temp**: temperatura mínima diaria registrada, en grados Celsius (°C).

Tras el preprocesamiento inicial, el dataset final queda compuesto por:

- **Número de observaciones**: 3650 días consecutivos.
- **Periodo cubierto**: del **1 de enero de 1981 al 31 de diciembre de 1990**.
- **Frecuencia temporal**: diaria, sin huecos aparentes en el calendario.

Este nivel de continuidad facilita el análisis de series de tiempo, pues se trata de una serie univariante limpia y regularmente muestreada.

### 4.2. Estadísticos descriptivos básicos

Sobre la variable Temp (ya convertida a tipo numérico) se calcularon estadísticas descriptivas básicas. De manera resumida:

- **Media:**  $\approx 11.19 \text{ } ^\circ\text{C}$
- **Mínimo:**  $0.0 \text{ } ^\circ\text{C}$
- **Mediana:**  $\approx 11.0 \text{ } ^\circ\text{C}$
- **Máximo:**  $26.3 \text{ } ^\circ$
- **Desviación estándar:**  $\approx 4.06 \text{ } ^\circ\text{C}$

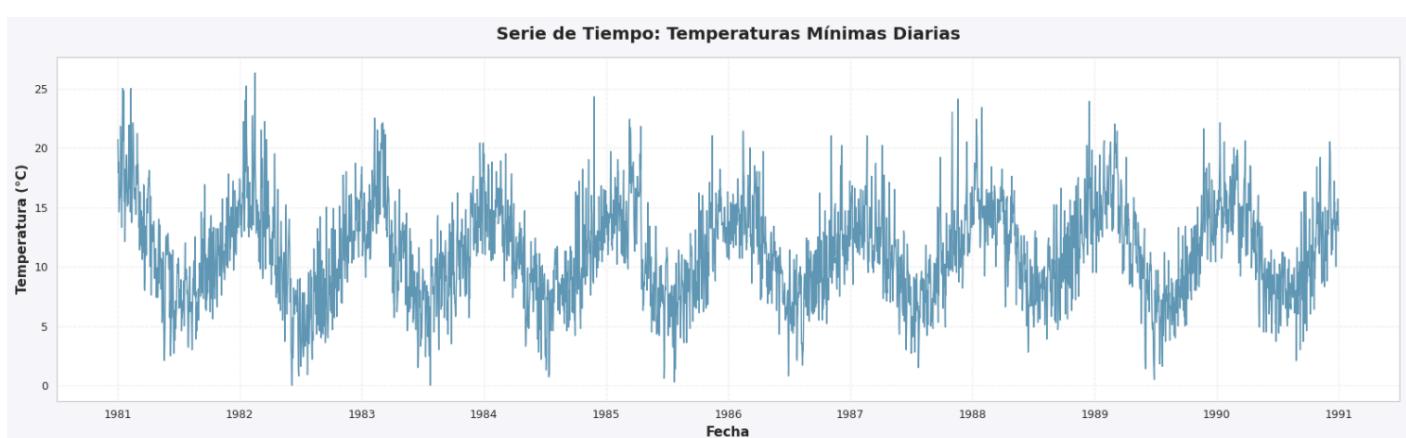
Estos valores indican que la mayor parte de las temperaturas mínimas se concentran en torno a los **10–12 °C**, con una dispersión moderada y algunos días puntualmente muy fríos (cerca de  $0 \text{ } ^\circ\text{C}$ ) o relativamente cálidos (por encima de  $20 \text{ } ^\circ\text{C}$ ). El conteo de temperaturas únicas y el histograma muestran una distribución **unimodal**, sin valores claramente aberrantes desde el punto de vista climático.

Durante la conversión de tipos se detectaron **3 valores faltantes** en la columna Temp, los cuales fueron imputados utilizando el **promedio de temperatura del mes correspondiente**. Tras esta imputación, la serie no presenta valores nulos y queda lista para su análisis y modelado.

#### 4.3. Características generales de la serie de tiempo

La **Figura 1** (serie completa Temp vs Date) permite apreciar la estructura global del proceso:

- Se observan **oscilaciones periódicas** muy marcadas cada  $\sim 365$  días, asociadas a los ciclos de verano e invierno del hemisferio sur.
- No se aprecia una **tendencia de largo plazo** claramente creciente o decreciente: los niveles medios de temperatura se mantienen aproximadamente estables a lo largo de la década.
- Aun dentro de cada año, la serie presenta **variaciones diarias** importantes, lo que introduce ruido de corto plazo que el modelo de pronóstico debe ser capaz de manejar.



El conteo de registros por año confirma que todos los años del periodo 1981–1990 contienen **365 observaciones**, por lo que la serie es completa y no hay años parciales. En conjunto, estos elementos muestran que se trata de una serie:

- **Univariante,**
- **Regularmente muestreada,**
- Dominada por una **estacionalidad anual fuerte,**
- Y con **tendencia prácticamente nula** en el horizonte temporal analizado.

Estas propiedades motivan el uso de modelos que exploten explícitamente la estacionalidad (por ejemplo, mediante términos de Fourier) y de ventanas temporales que capturen tanto la dependencia de corto plazo como el patrón anual en el diseño de los modelos de pronóstico.

## 5. Análisis exploratorio y propiedades de la serie

### 5.1. Visualización de la serie completa

La **Figura 2** muestra la evolución de la temperatura mínima diaria en Melbourne entre 1981 y 1990. A simple vista se identifican tres características clave:

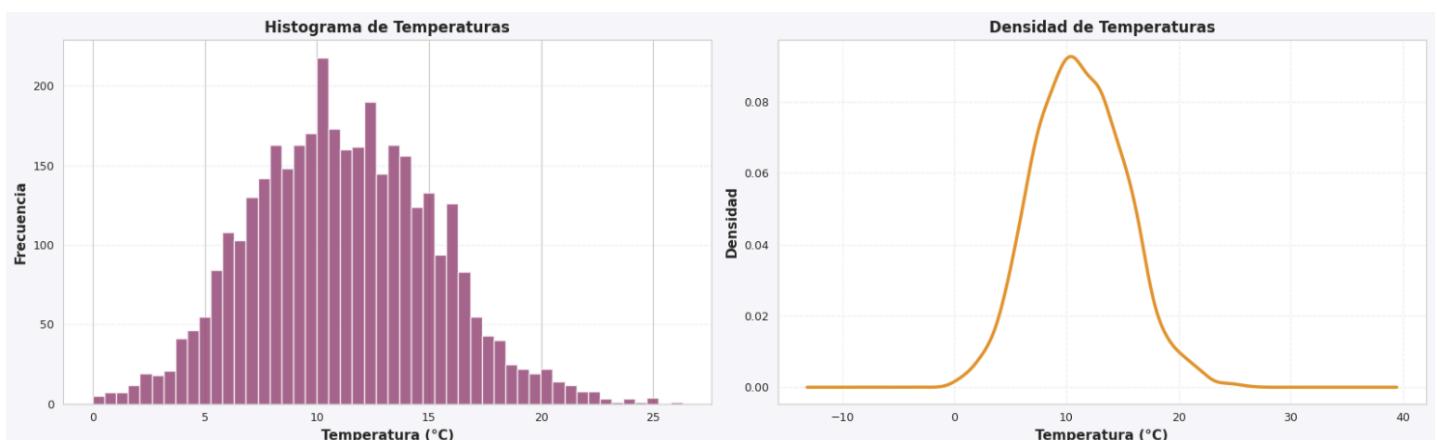
1. **Estacionalidad anual muy marcada:** las temperaturas mínimas aumentan y disminuyen de forma casi periódica cada 12 meses, con veranos más cálidos e inviernos más fríos.
2. **Ausencia de tendencia pronunciada:** no se observa un incremento o decremento sistemático de la temperatura media a lo largo de la década; el nivel medio de la serie se mantiene alrededor de 11–12 °C.
3. **Variabilidad de corto plazo:** aun dentro de cada año hay oscilaciones diarias considerables, lo que indica que el modelo deberá capturar tanto el patrón estacional como el ruido de alta frecuencia.

Estas observaciones iniciales ya sugieren la conveniencia de incorporar explícitamente la estacionalidad anual en el modelado.

## 5.2. Distribución de temperaturas

Para estudiar la distribución marginal de Temp se construyeron un **histograma** y una **curva de densidad (KDE)** (Figura 3). Los resultados muestran que:

- La distribución es **unimodal**, centrada en torno a los 10–12 °C.
- La mayor parte de los valores se encuentran en el rango de **5 a 15 °C**.
- Existen pocos días con temperaturas extremas, cercanas a **0 °C** o por encima de **20 °C**, que son coherentes con episodios de frío intenso o noches particularmente cálidas.



Dado que estos valores extremos son físicamente plausibles para el clima de Melbourne, se decidió **no eliminarlos** como outliers, sino mantenerlos como parte de la variabilidad natural del proceso.

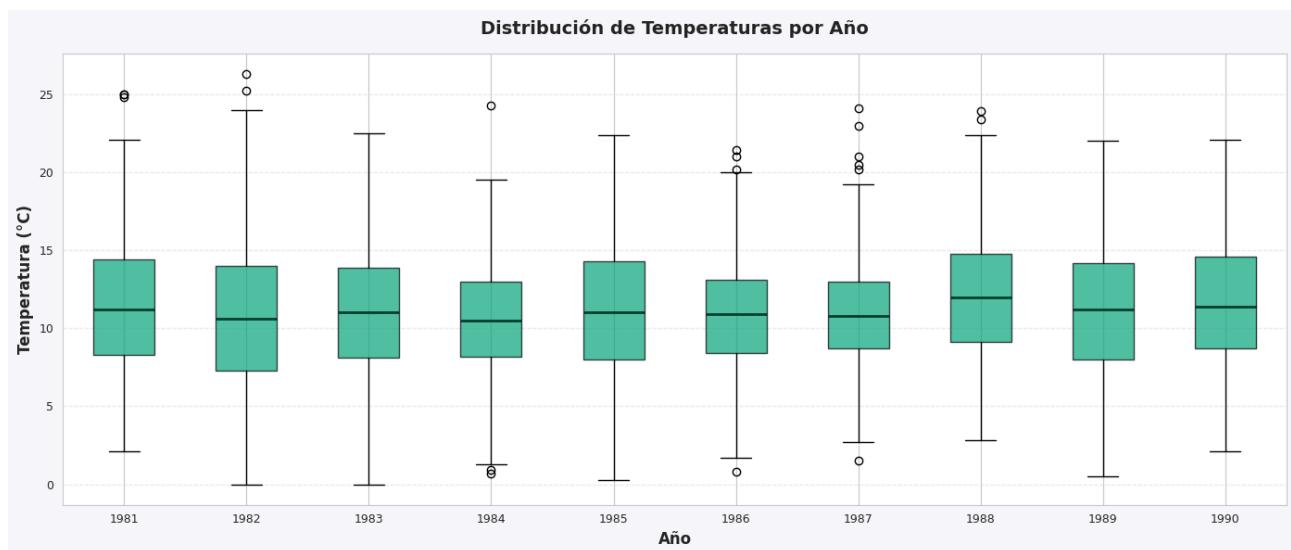
## 5.3. Análisis por año

Se calcularon estadísticas descriptivas por año y se representaron mediante **boxplots anuales** y una gráfica de **temperatura promedio por año** (Figuras 4 y 5). De este análisis se concluye que:

- La mediana y los cuartiles de temperatura son muy similares de un año a otro.

- Los rangos intercuartílicos apenas varían, y las diferencias entre las medias anuales se mantienen dentro de unos pocos décimos de grado.
- No se aprecia una tendencia clara de calentamiento o enfriamiento en el periodo 1981–1990.

En conjunto, los resultados indican que la variabilidad más relevante es **intra-anual** (estacional), mientras que la variabilidad interanual es relativamente pequeña.

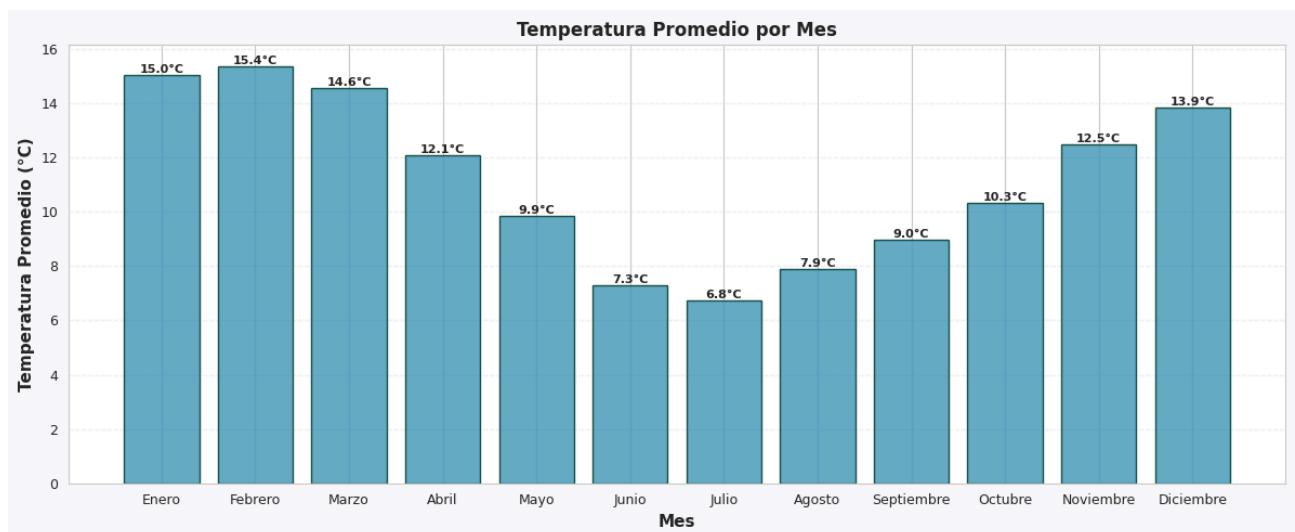
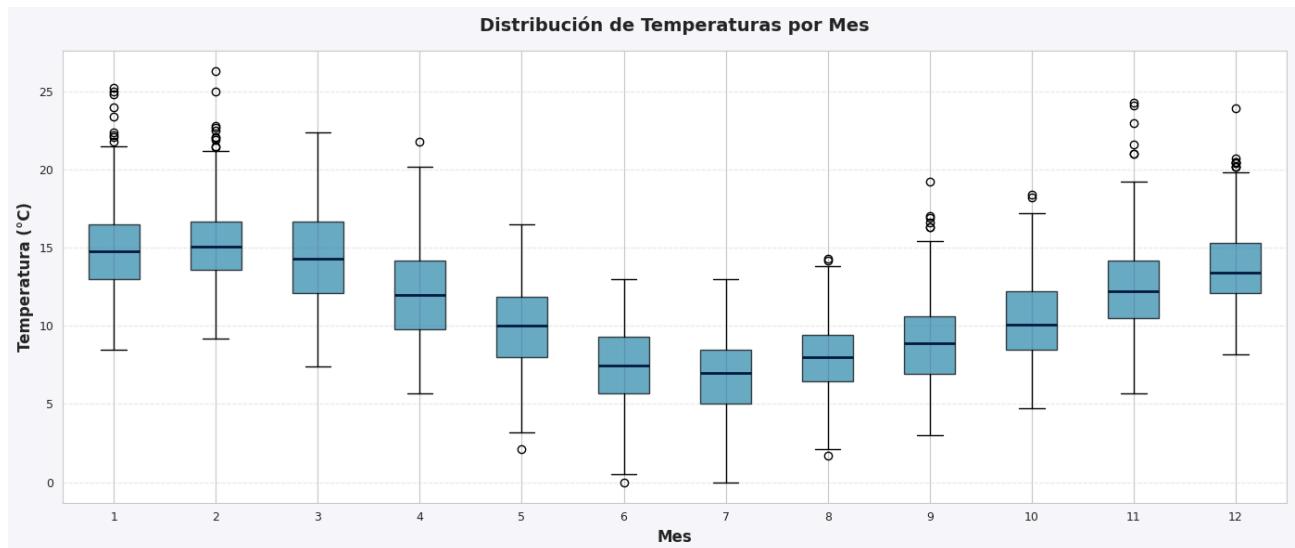


#### 5.4. Análisis por mes y patrón estacional

Para caracterizar la estacionalidad se agruparon las observaciones por **mes del año**. Los **boxplots mensuales** y la gráfica de **temperatura media mensual** (Figuras 6 y 7) revelan un patrón casi sinusoidal:

- Las temperaturas mínimas más bajas se observan en los meses de **invierno austral** (junio y julio).
- Las temperaturas más altas se concentran en el **verano austral** (diciembre, enero y febrero).
- Los meses de transición (otoño y primavera) presentan valores intermedios, configurando una curva suave que desciende desde el verano hasta el invierno y luego vuelve a ascender.

Este comportamiento coincide con la climatología esperada para una ciudad del **hemisferio sur** y confirma que la serie está fuertemente dominada por un componente estacional anual de amplitud casi constante.

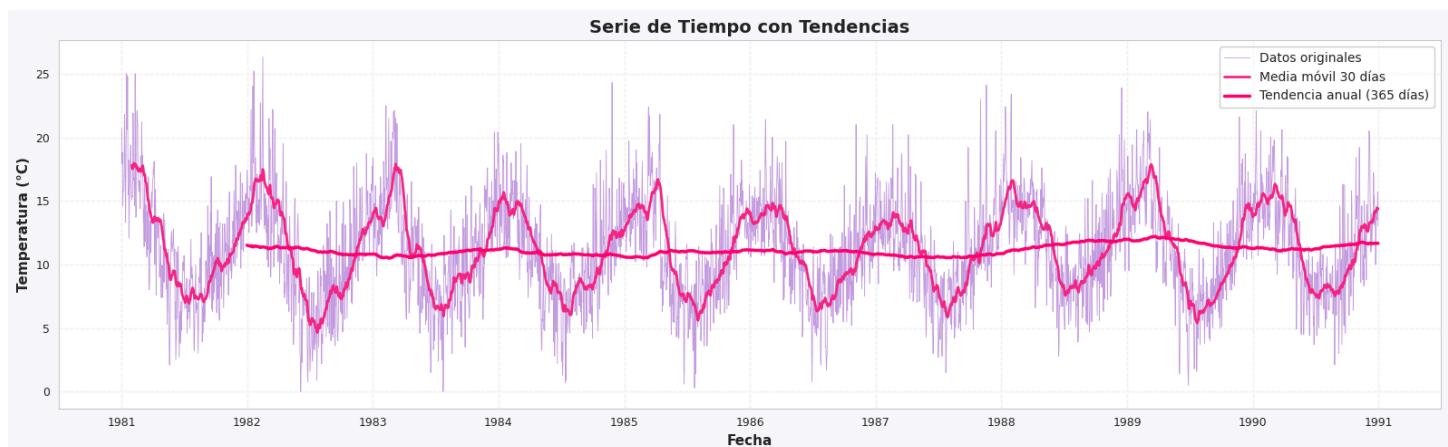


## 5.5. Tendencia y medias móviles

Para separar parcialmente la variabilidad de corto plazo de la estructura de mediano y largo plazo se calcularon dos medias móviles sobre la serie:

- **Media móvil de 30 días**, que suaviza el ruido diario y resalta la estacionalidad anual.
- **Media móvil de 365 días**, que actúa como aproximación de la tendencia de fondo.

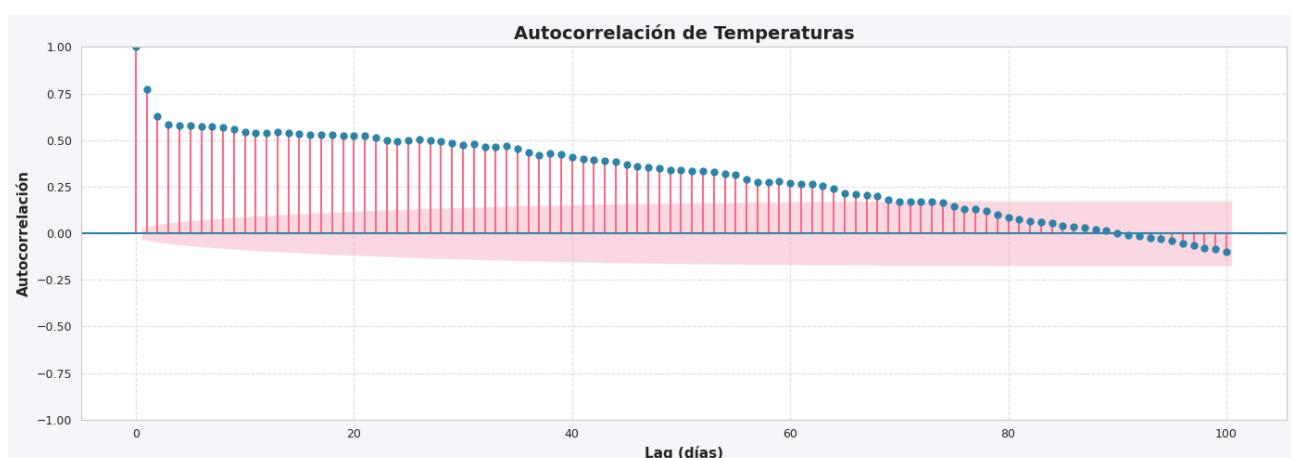
La **Figura 8** muestra que la media móvil de 30 días sigue claramente el ciclo anual de la temperatura, mientras que la media móvil de 365 días se mantiene prácticamente **plana** durante toda la década. Esto respalda la idea de que la serie puede considerarse aproximadamente **estacionaria alrededor de una media constante**, una vez controlada la estacionalidad.



## 5.6. Autocorrelación, autocorrelación parcial y descomposición

Las funciones de **autocorrelación (ACF)** y **autocorrelación parcial (PACF)** se calcularon sobre la serie de temperatura (Figuras 9 y 10). Los resultados muestran que:

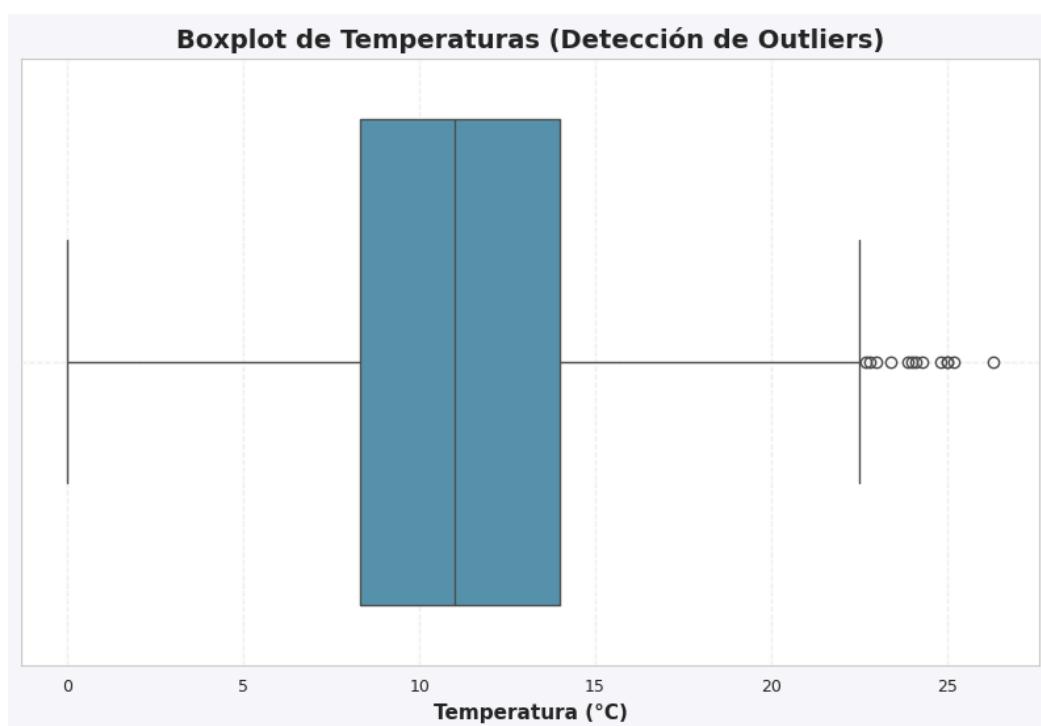
- La ACF presenta valores muy altos en lags cortos y una caída lenta, manteniendo correlaciones significativas durante varias decenas de días. Esto indica una fuerte dependencia temporal: la temperatura de hoy está relacionada con la de varios días y semanas anteriores.
- La PACF exhibe un pico dominante en el **lag 1** y algunos lags adicionales de menor magnitud, lo que es consistente con un comportamiento autorregresivo de **bajo orden**.



## 5.7. Valores atípicos y consistencia climática

Finalmente, se utilizó un **boxplot global** de Temp para inspeccionar posibles valores atípicos. Aunque se identifican algunos puntos más alejados de la mediana, estos corresponden a días extremadamente fríos o cálidos que siguen siendo físicamente compatibles con el clima local. Por esta razón:

- No se aplicó ninguna regla automática de eliminación de outliers.
- Se decidió **conservar todos los registros**, privilegiando la fidelidad a la serie observada frente a una limpieza excesiva que pudiera distorsionar la variabilidad real.



En resumen, el análisis exploratorio confirma que la serie de temperatura mínima diaria de Melbourne es:

- **Univariada y regularmente muestreada,**
- Con **estacionalidad anual muy marcada**,
- Sin tendencia de largo plazo relevante,
- Y con fuerte **autocorrelación** en lags de corto y mediano plazo.

Estas propiedades justifican el uso de **ventanas temporales de 30 días** como entrada de los modelos, la incorporación de **términos de Fourier** para capturar la estacionalidad y la comparación entre enfoques estadísticos, de *machine learning* y de *deep learning* en las secciones posteriores.

## 5.8. Aproximación senoidal mediante términos de Fourier

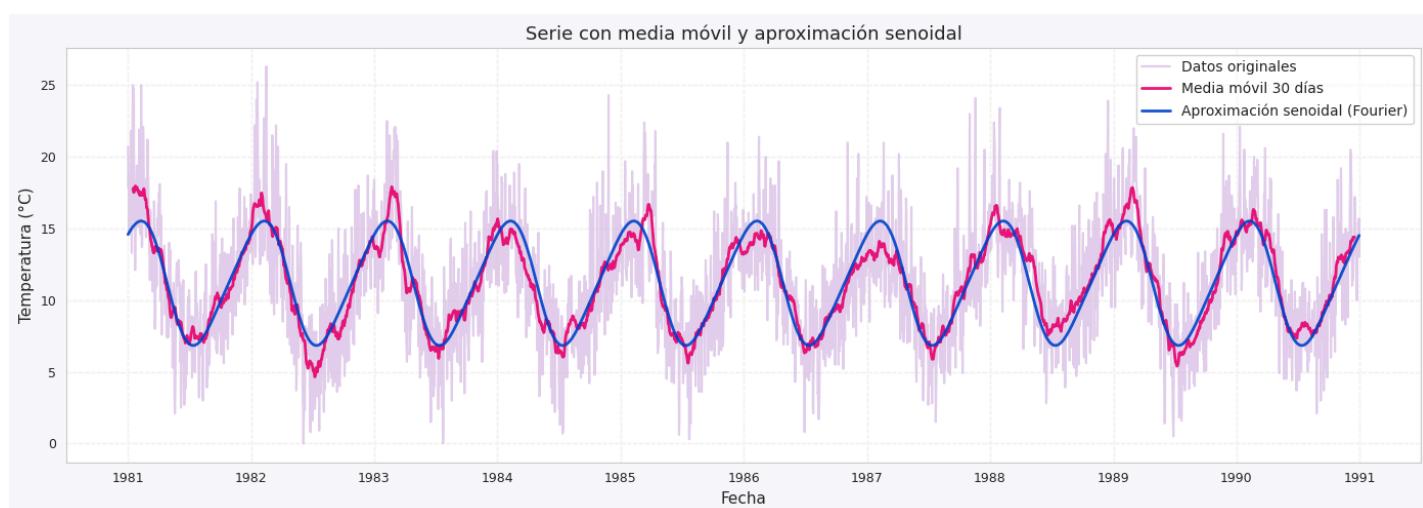
En la **Figura 11** se muestra la serie de temperatura mínima diaria junto con dos curvas suavizadas:

- (i) la **media móvil de 30 días**, y
- (ii) una **aproximación senoidal obtenida con términos de Fourier** (regresión armónica con K=2 armónicos).

La media móvil de 30 días (línea magenta) elimina gran parte del ruido diario, revelando un ciclo anual muy regular. La curva azul, ajustada mediante una regresión lineal sobre senos y cosenos con periodo de 365 días, reproduce con notable precisión esa oscilación estacional. Esto constituye un resultado clave del análisis exploratorio:

**La estacionalidad dominante de la serie puede modelarse de forma explícita mediante términos de Fourier**, sin necesidad de recurrir aún a modelos complejos de *deep learning*.

Este hallazgo motiva la inclusión de una **regresión armónica** como uno de los modelos base del proyecto y justifica, en la sección de Metodología, el uso de términos de Fourier como representación compacta y explicable de la estacionalidad anual.



## 6. Metodología (Preprocesamiento, modelos y configuración)

En esta sección se describe el flujo completo seguido para preparar la serie, generar las ventanas temporales y entrenar los distintos modelos de pronóstico: LSTM, XGBoost, Regresión Armónica y el Ensamble híbrido.

### 6.1. Preprocesamiento de la serie

El archivo original contenía una sola columna de texto llamada Date,Temp, donde la fecha y la temperatura estaban unidas por una coma (por ejemplo: 06/18/85,7.3).

Los pasos de limpieza fueron:

- **Separación de variables**

Se dividió la columna Date,Temp en dos columnas:

- Date: fecha en formato cadena.

- Temp: temperatura mínima diaria en formato cadena.

- **Conversión de tipos**

- La columna Date se convirtió a tipo fecha (datetime), usando el formato mes/día/año.

- La columna Temp se convirtió a número real (float).

- En este proceso aparecieron 3 valores faltantes en Temp (valores no reconocidos como número).

- **Imputación de valores faltantes**

- Se calculó la temperatura media para cada mes del año.

- Cada valor faltante de Temp se sustituyó por la media del mes correspondiente.

- Después de esta imputación, la serie ya no tenía valores nulos.

- **Variables auxiliares para EDA**

- Solo para el análisis exploratorio se generaron columnas auxiliares:

- Año (Year), mes (Month),

- Media móvil de 30 días (MA\_30)
- Media móvil de 365 días (MA\_365).

- Estas columnas sirvieron para estudiar tendencia y estacionalidad, pero **no se usaron como entrada de los modelos finales**.

- **Serie final para modelar**

- Antes de la fase de modelado, se eliminaron las columnas auxiliares y se trabajó con una serie univariante limpia formada únicamente por:

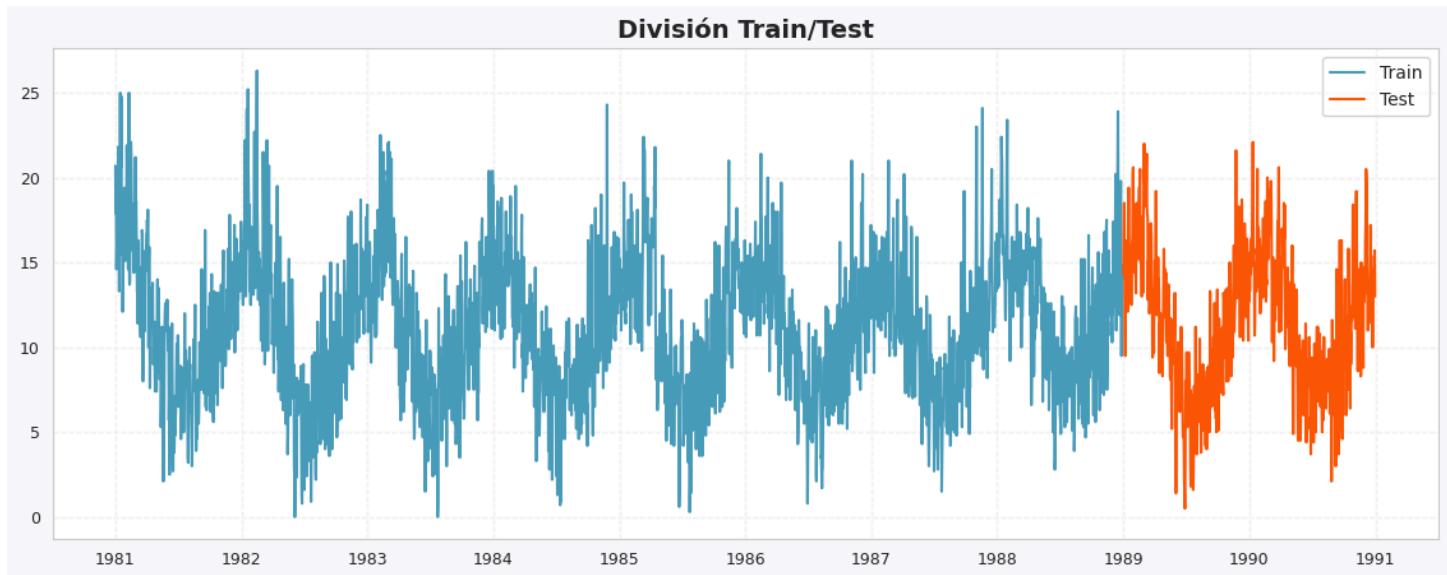
- Date

- Temp.

## 6.2. División train/test y escalado

Para evaluar el desempeño de forma realista se dividió la serie respetando el tiempo:

- **Entrenamiento (train):** primeros 80 % de los días (2920 observaciones).
- **Prueba (test):** 20 % final de la serie (730 observaciones).
- No se barajaron los datos; la división fue puramente cronológica.



Dado que varios modelos (LSTM y XGBoost) son sensibles a la escala de las variables, se aplicó un **escalado MinMax** a la columna Temp:

- El escalador se ajustó **solo con los datos de entrenamiento**, para evitar que la información del futuro influya en el pasado.
- Una vez ajustado, se utilizó el mismo escalador para transformar tanto el conjunto de entrenamiento como el de prueba, llevando la temperatura a un rango aproximado entre 0 y 1.

## 6.3. Ventanas temporales y horizonte de pronóstico

Con base en la ACF/PACF y en la interpretación física del problema, se decidió:

- Usar como **entrada** los últimos **30 días** de temperatura mínima (ventana de 30 pasos).
- Predecir como **salida** la temperatura de los **siguientes 7 días** (horizonte de 7 pasos).

En la práctica, esto se implementó creando:

- Un conjunto de matrices X, donde cada fila contiene 30 valores consecutivos de temperatura escalada.
- Un conjunto de etiquetas y, donde cada fila contiene las 7 temperaturas inmediatamente posteriores a esa ventana.

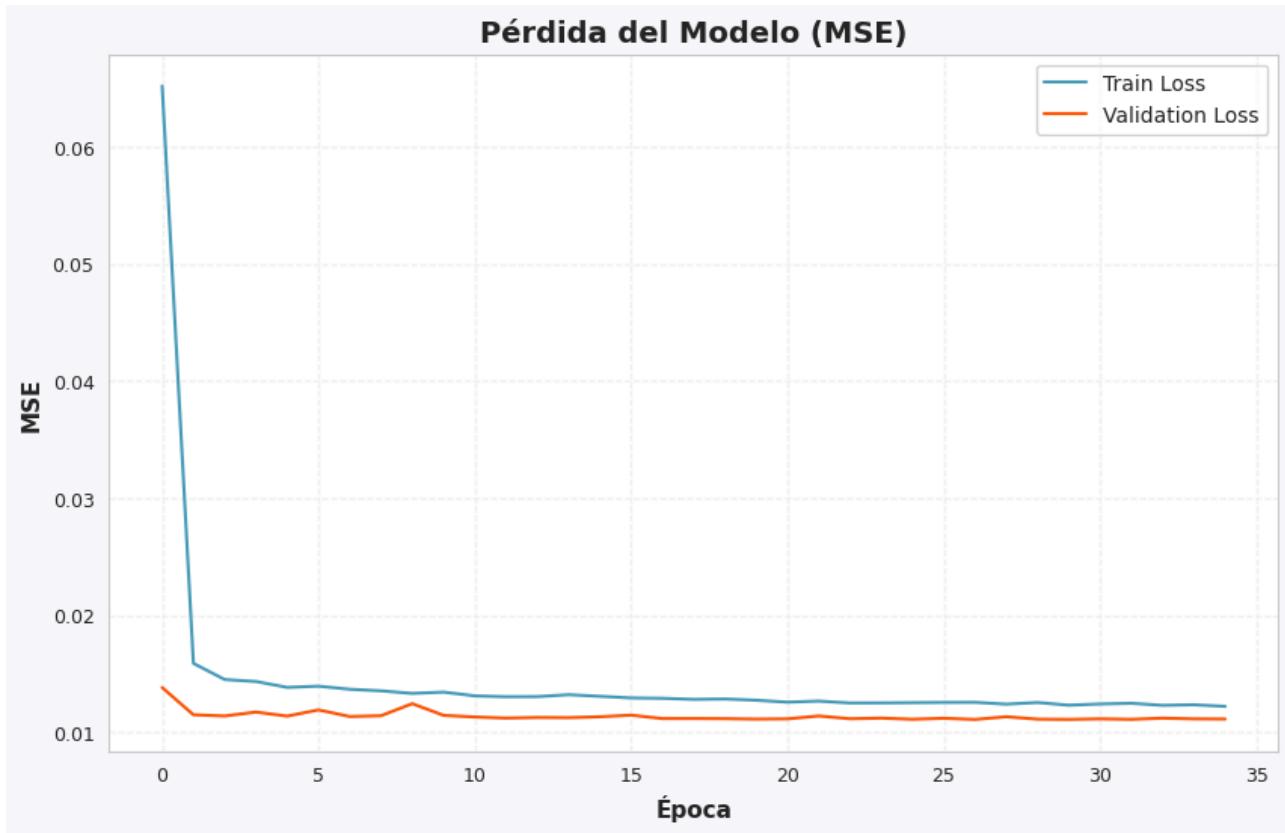
Para la LSTM, estas secuencias se reorganizaron a un formato tridimensional (muestras × pasos de tiempo × características), mientras que para XGBoost se aplanaron a un vector de 30 elementos por muestra.

#### 6.4. Modelo LSTM (Deep Learning)

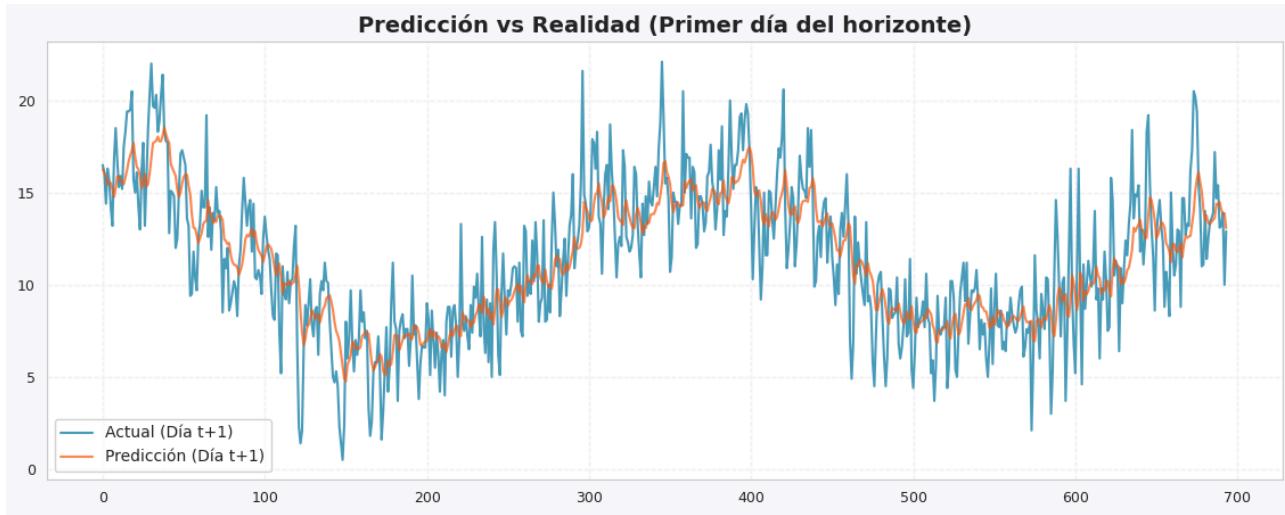
El primer modelo de pronóstico basado en redes neuronales fue una **LSTM univariante multistep**. Su configuración principal fue:

- **Entrada:** secuencia de 30 días de temperatura escalada (1 característica).
- **Arquitectura:**
  - Una capa LSTM con **64 unidades**, que resume la información de toda la secuencia en un vector interno.
  - Una capa **Dropout** con probabilidad 0.2 para reducir el sobreajuste.
  - Una capa densa intermedia de **32 neuronas** con activación ReLU.
  - Una capa de salida densa con **7 neuronas**, una por cada día del horizonte de pronóstico.
- **Entrenamiento:**
  - Función de pérdida: **MSE** (error cuadrático medio) sobre los 7 días.
  - Optimizador: **Adam** con tasa de aprendizaje 0.001.
  - Tamaño de lote: 64.
  - Máximo de 100 épocas, pero con **Early Stopping** monitorizando la pérdida de validación (quedando 40 épocas aprox)
    - Si la val\_loss no mejoraba después de 8 épocas consecutivas, se detenía el entrenamiento y se restauraban los mejores pesos.\

Este modelo se utilizó tanto para evaluar el desempeño en el conjunto de prueba como para generar el pronóstico de los 7 días posteriores al final de la serie (enero de 1991).



Logramos un RMSE de 2.68 y un MAE DE 2.06 lo cual es bastante bueno en temperatura pues solo estamos a +/- 2.06 C del resultado



## 6.5. Modelo XGBoost (Machine Learning)

Como representante de *machine learning* basado en árboles se empleó un **XGBoost Regressor** configurado para producir directamente el vector de 7 días futuros.

Pasos clave:

## 1. Transformación de la entrada

- Cada ventana de 30 días se aplanó a un vector de longitud 30 (una fila por muestra).
- De esta manera, XGBoost ve cada ejemplo como un registro tabular con 30 columnas numéricas.

## 2. Predicción multisalida

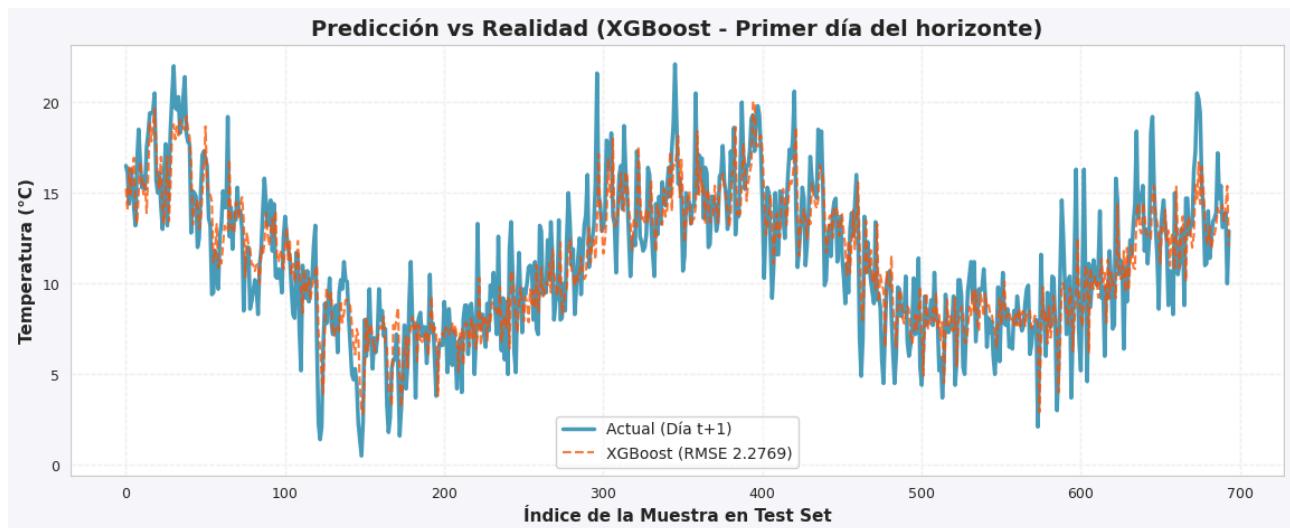
- Se utilizó un envoltorio de MultiOutputRegressor, que permite entrenar un conjunto de modelos XGBoost, uno por cada día del horizonte.
- El modelo resultante produce, para cada fila de entrada, un vector de 7 temperaturas escaladas.

## 3. Configuración base del estimador

- Número de árboles (n\_estimators): 100.
- Tasa de aprendizaje (learning\_rate): 0.1.
- Semilla (random\_state): 42, para reproducibilidad.

Las predicciones de XGBoost, generadas inicialmente en escala [0, 1], se transformaron de vuelta a grados Celsius utilizando el mismo escalador MinMax que se había ajustado sobre el conjunto de entrenamiento.

Los resultados obtenidos por este modelo son: **RMSE 2.731347 MAE 2.123313**



## 6.6. Regresión Armónica (Harmonic Regression con Fourier)

El análisis exploratorio mostró que la estacionalidad anual se ajusta muy bien a una forma casi senoidal. Para explotar esta estructura se implementó una **regresión lineal con**

**términos de Fourier**, que actúa como un modelo estadístico interpretable y de baja complejidad.

Pasos principales:

### 1. Construcción de variables temporales

- Se generó un índice temporal  $t$  que va de 1 a N (número total de días).
- Se calculó el **día del año** (day\_of\_year), de 1 a 365.
- Se añadieron términos senoidales y cosenoidales para los primeros **dos armónicos** ( $K = 2$ ) con periodo de 365 días:

### 2. Modelo

Se ajustó una regresión lineal utilizando como predictores:

- La variable de tiempo  $t$  ( posible tendencia).
- Los términos seno y coseno de orden 1 y 2.
- La salida del modelo es directamente la temperatura en °C.

### 3. División temporal

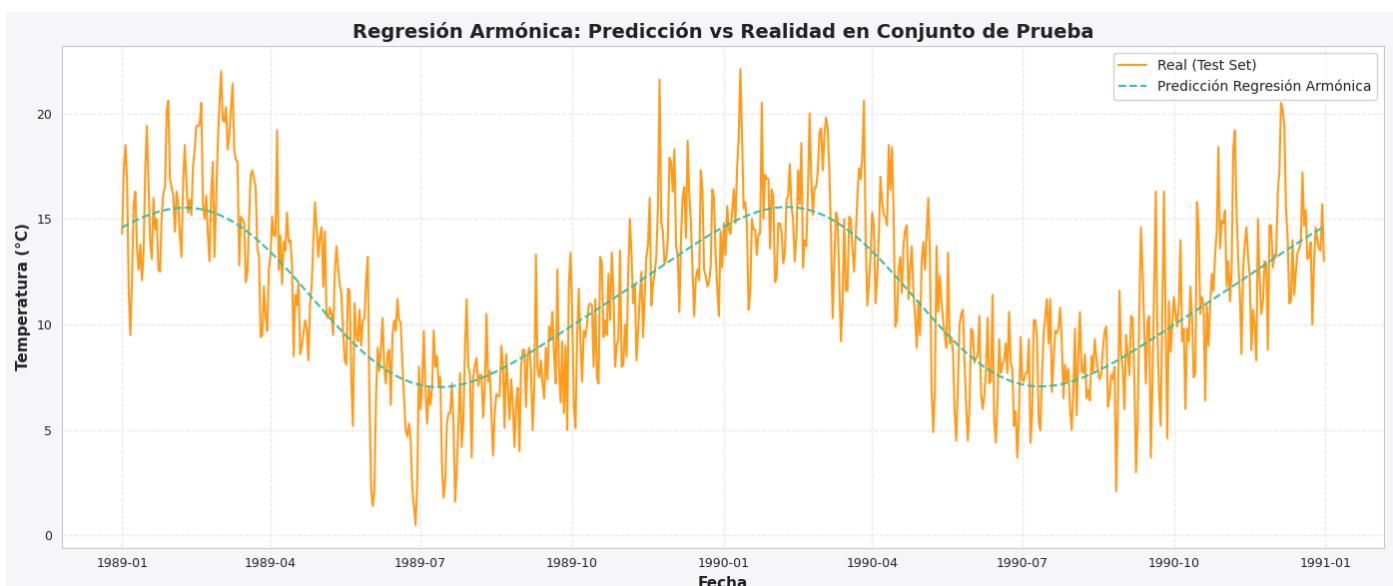
- Se mantuvo la misma lógica 80/20 temporal para separar datos de entrenamiento y prueba.

Este modelo captura de forma compacta:

- La **tendencia de largo plazo** (si existe) mediante  $t$ .
- La **estacionalidad anual** mediante las series de Fourier.

Los resultados obtenidos en este modelo son: **MAE : 1.9683 °C, RMSE: 2.5298 °C,**

**MAPE: 24.44 %**



## 6.7. Ensamble Híbrido (Regresión Armónica + XGBoost)

Finalmente, para aprovechar lo mejor de ambos mundos, se construyó un **ensamble híbrido** entre:

- La **Regresión Armónica**, que proporciona una base suave, periódica y físicamente coherente.
- El **XGBoost**, que captura la variabilidad local y los patrones no lineales de corto plazo.

La combinación se hizo a nivel de predicción, centrándose primero en el horizonte de **1 día adelante**:

1. Se alinearon las predicciones:

- $\hat{y}_{\text{harmonic}}(t+1)$ : predicción del modelo armónico para cada día del conjunto de prueba.
- $\hat{y}_{\text{xgb}}(t+1)$ : predicción de XGBoost (ya revertida a  $^{\circ}\text{C}$ ) para el mismo día.

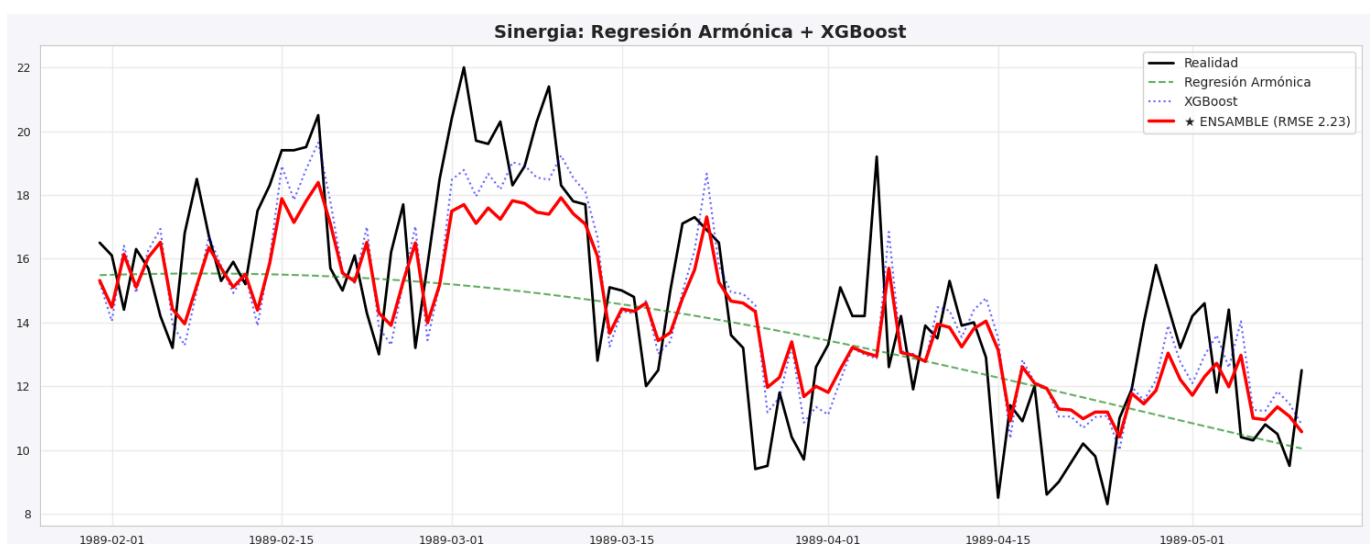
2. Se calculó una combinación lineal ponderada:

**y\_pred\_ensamble = 0.3 \* pred\_harmonic\_aligned + 0.7 \* pred\_xgb\_1day\_inv\_aligned**

- El peso 0.3 se asignó al modelo armónico (que actúa como “ancla estacional”).
- El peso 0.7 se asignó a XGBoost (que corrige y ajusta detalles de corto plazo).

Este ensamble resultó ser el modelo con mejor desempeño global (menor RMSE y MAE) y se eligió como **modelo final** para interpretar el pronóstico y discutir la plausibilidad física de las temperaturas proyectadas para la primera semana de 1991.

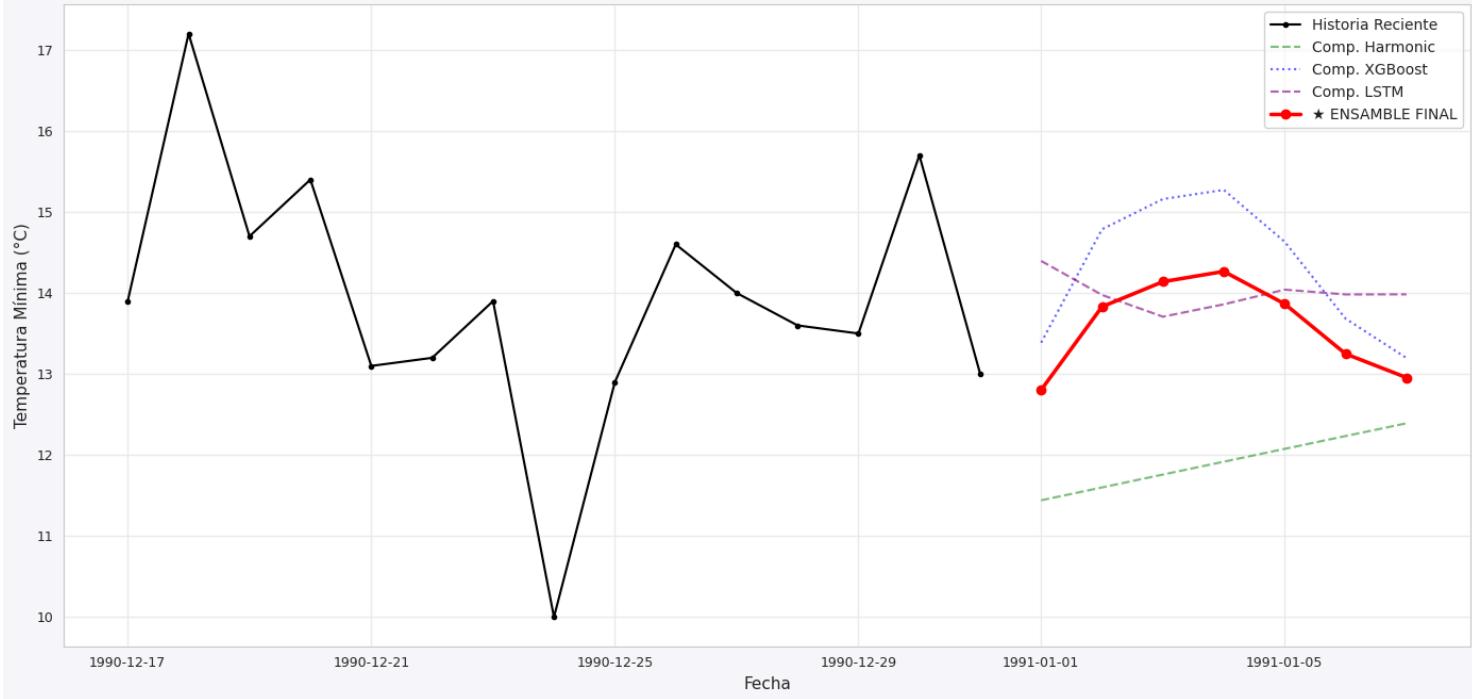
**Resultados del Ensamble: MAE: 1.7508  $^{\circ}\text{C}$ , RMSE: 2.2282  $^{\circ}\text{C}$**



## TABLA FINAL DE PRONÓSTICOS FUTUROS (1991)

Date	Harmonic	XGBoost	LSTM	ENSEAMBLE FINAL
1991-01-01	11.44	13.39	14.40	12.80
1991-01-02	11.60	14.79	13.98	13.83
1991-01-03	11.76	15.16	13.71	14.14
1991-01-04	11.92	15.27	13.86	14.27
1991-01-05	12.08	14.63	14.04	13.87
1991-01-06	12.23	13.68	13.98	13.25
1991-01-07	12.39	13.20	13.98	12.96

Pronóstico 1991: Comparativa de Todos los Modelos



## 7. Resultados y comparación de modelos

En esta sección se presentan los resultados cuantitativos y cualitativos obtenidos con los cuatro enfoques de modelado implementados:

- **LSTM** (red neuronal recurrente).
- **XGBoost** (modelo de *gradient boosting* sobre árboles).
- **Regresión Armónica** (modelo estadístico con términos de Fourier).
- **Ensamble Híbrido** (combinación de Regresión Armónica + XGBoost).

Se analizan primero las métricas globales de pronóstico para un horizonte de 7 días y, posteriormente, el desempeño específico a 1 día adelante, junto con la interpretación visual de las curvas pronosticadas y del pronóstico fuera de muestra para enero de 1991.

### 7.1. Métricas globales (horizonte de 7 días)

Para evaluar la precisión de los modelos en el horizonte completo de 7 días se calcularon las métricas MAE, RMSE y MAPE sobre todas las predicciones del conjunto de prueba, transformadas de vuelta a grados Celsius.

- **LSTM**
  - MAE ≈ **2.06 °C**
  - RMSE ≈ **2.67 °C**
  - MAPE ≈ **26.7 %**
- **Regresión Armónica**
  - MAE ≈ **1.97 °C**
  - RMSE ≈ **2.53 °C**
  - MAPE ≈ **24.4 %**
- **XGBoost**
  - MAE ≈ **2.12 °C**
  - RMSE ≈ **2.73 °C**
  - MAPE ≈ **26.5 %**
- **Ensamble Híbrido (Harmonic + XGBoost)**
  - MAE ≈ **1.75 °C**
  - RMSE ≈ **2.23 °**

Aunque los tres modelos individuales ya logran errores relativamente bajos (todos con RMSE alrededor de 2.5–2.7 °C y MAE cerca de 2 °C), el **ensamble híbrido** consigue una reducción consistente de ambos errores:

- Disminuye el RMSE en casi **0.5 °C** respecto a los modelos neuronales y de boosting.
- Disminuye el MAE a alrededor de **1.75 °C**, es decir, en promedio se equivoca menos de 2 grados.

En términos prácticos, esto significa que el ensamble puede predecir la temperatura mínima diaria de Melbourne con un error típico de alrededor de **±1.8 °C**, lo cual es razonable para un problema meteorológico con una única variable de entrada.

Además, el mejor MAPE corresponde también al modelo que captura explícitamente la estacionalidad (Regresión Armónica) y, por combinación, al Ensamble. El MAPE es relativamente alto ( $\approx 24\text{--}27\%$ ) porque en algunos días invernales las temperaturas se acercan a 0 °C; al tener denominadores muy pequeños, cualquier error moderado se traduce en un porcentaje elevado. Por esta razón, **MAE y RMSE son métricas más informativas** en este contexto.

## 7.2. Desempeño específico a 1 día adelante

Dado que en meteorología suele ser especialmente importante el pronóstico a corto plazo, se realizó un análisis adicional únicamente para el primer paso del horizonte (día t+1). Al restringir la evaluación a 1 día adelante, los resultados fueron:

- |  |   |
|--|---|
| <ul style="list-style-type: none"><li>• <b>LSTM (1 día)</b><ul style="list-style-type: none"><li>○ RMSE <math>\approx 2.40\text{ °C}</math></li><li>○ MAE <math>\approx 1.86\text{ °C}</math></li></ul></li><li>• <b>XGBoost (1 día)</b><ul style="list-style-type: none"><li>○ RMSE <math>\approx 2.28\text{ °C}</math></li><li>○ MAE <math>\approx 1.80\text{ °C}</math></li></ul></li></ul> | <ul style="list-style-type: none"><li>• <b>Regresión Armónica (1 día)</b><ul style="list-style-type: none"><li>○ RMSE <math>\approx 2.54\text{ °C}</math></li><li>○ MAE <math>\approx 1.97\text{ °C}</math></li></ul></li><li>• <b>Ensamble Híbrido (1 día)</b><ul style="list-style-type: none"><li>○ RMSE <math>\approx 2.23\text{ °C}</math></li><li>○ MAE <math>\approx 1.75\text{ °C}</math></li></ul></li></ul> |
|--|---|

Se observa nuevamente el mismo patrón:

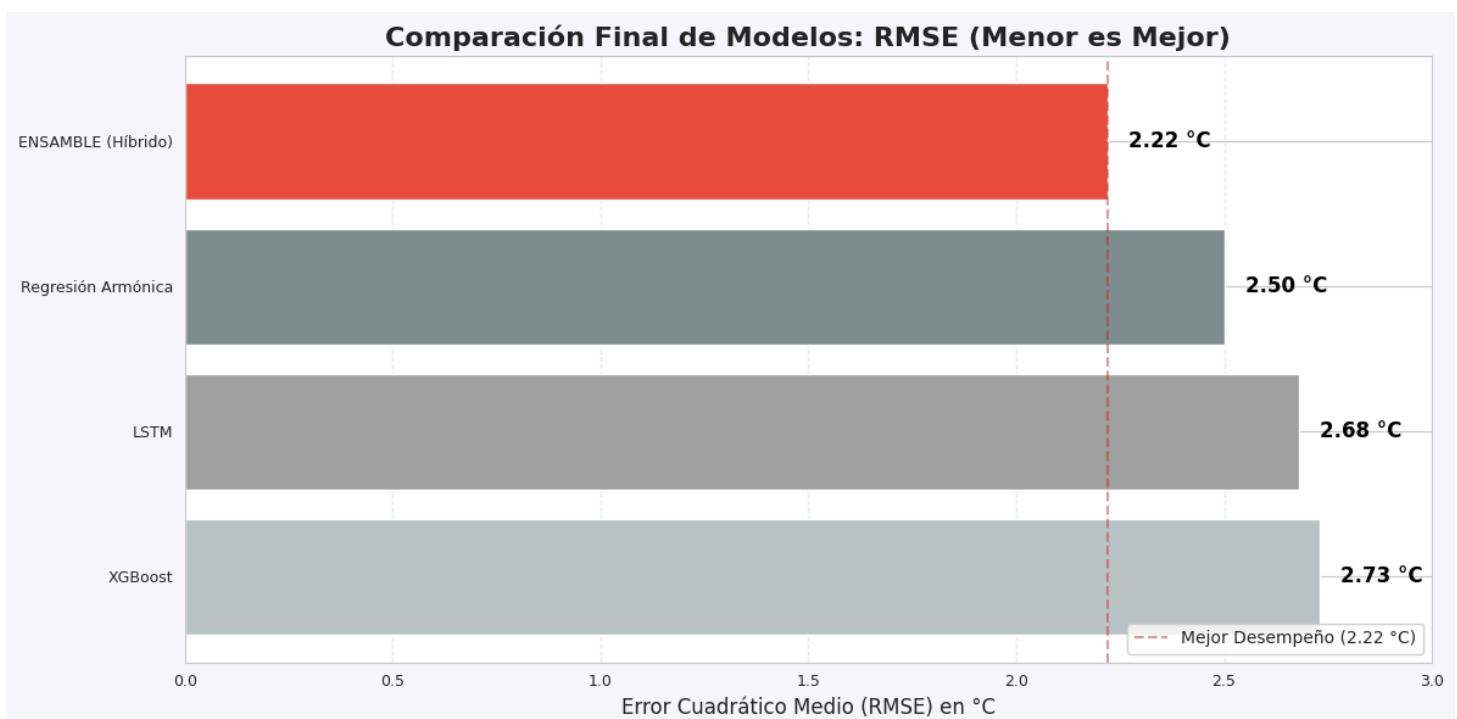
1. **XGBoost mejora ligeramente a la LSTM** cuando solo se evalúa el primer día (menor RMSE y MAE).
2. La **Regresión Armónica**, aunque algo peor en RMSE para 1 día, sigue siendo competitiva en MAE.
3. El **Ensamble Híbrido** vuelve a ser el modelo ganador, con los menores errores en ambas métricas.

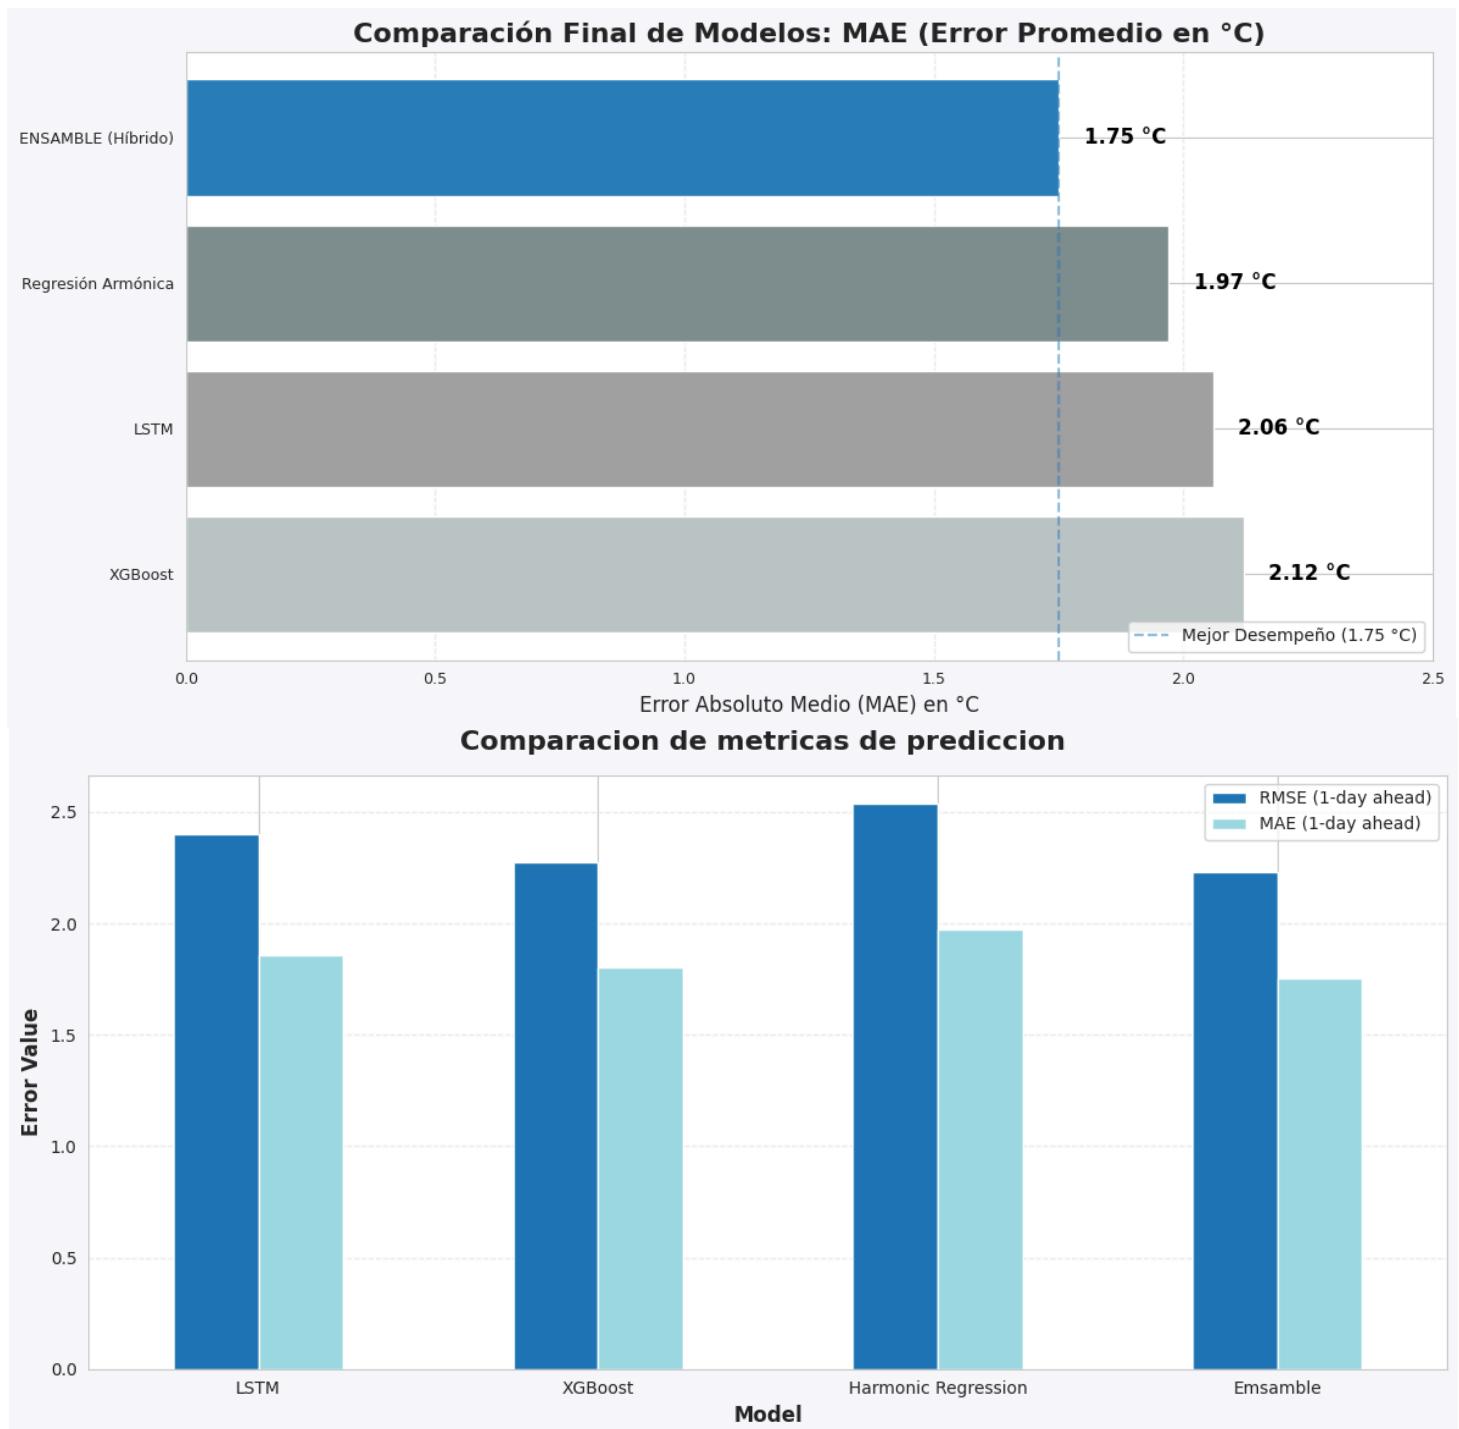
En términos de MAPE para 1 día (gráfico de barras incluido en el notebook), los valores se sitúan aproximadamente en:

- LSTM: ~45 %
- XGBoost: ~43 %
- Regresión Armónica: ~47 %
- Ensamble: ~4

De nuevo, estos porcentajes hay que interpretarlos con cuidado porque las divisiones por temperaturas cercanas a 0 °C inflan artificialmente el porcentaje de error. Aun así, el ensamble logra el **menor MAPE** y confirma la mejora relativa frente a los modelos individuales.

Por ejemplo, el día 13/10/1989 la temperatura real fue ~17.2 °C y el modelo la subestimó en más de 3.5 °C. Este tipo de errores suele ocurrir cuando... (transición rápida de días fríos a cálidos / evento atípico que el modelo no puede anticipar solo con información de temperatura pasada).





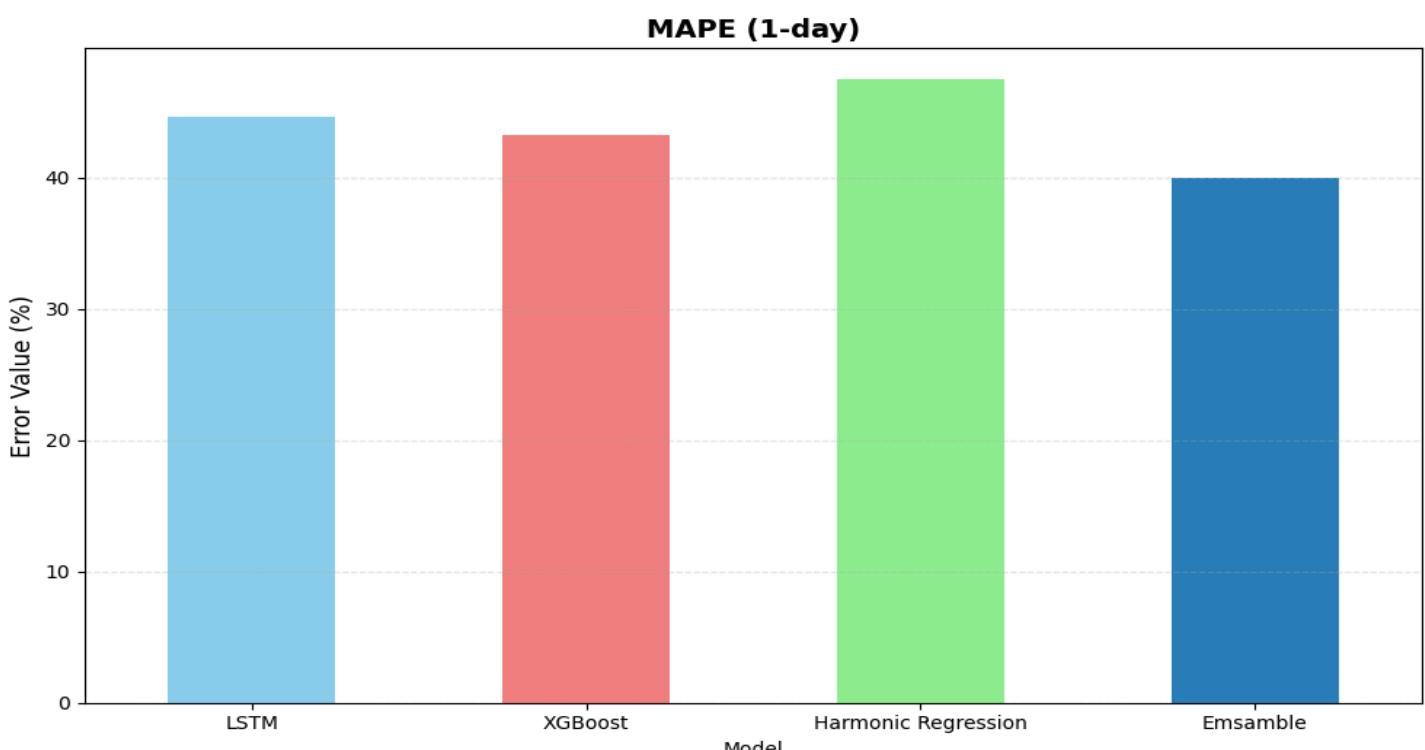
### 7.3. Discusión general de los resultados

A partir de todos los análisis, se pueden extraer varias conclusiones:

- Todos los modelos son competitivos**, con errores promedio alrededor de 2 °C, lo que ya es aceptable para una serie univariante de temperatura mínima diaria sin información adicional (humedad, presión, viento, etc.).

2. La **Regresión Armónica** muestra que una parte muy importante de la dinámica puede explicarse con un modelo **simple, interpretable y determinista**, basado en tendencia + Fourier. Por sí sola, consigue errores incluso mejores que LSTM y XGBoost en algunas métricas globales.
3. Los modelos de **Deep Learning (LSTM)** y de **Machine Learning (XGBoost)** tienen ventajas complementarias:
  - LSTM produce curvas suaves y físicamente razonables, pero puede “promediar en exceso” las oscilaciones.
  - XGBoost captura bien la variabilidad de corto plazo, aunque introduce algo más de ruido en la señal
4. El **Ensamble Híbrido** logra combinar lo mejor de cada enfoque:
  - La estabilidad y la estacionalidad clara de la Regresión Armónica.
  - La capacidad de ajuste local de XGBoost.

El resultado es un modelo con **menor RMSE y MAE**, tanto en el horizonte completo de 7 días como en el primer día de pronóstico, y con un comportamiento visual coherente.
5. Desde una perspectiva de ingeniería, el proyecto ilustra que, en series de tiempo climáticas con **pocos años de datos** pero **estacionalidad fuerte**, una estrategia basada en:
  - **Modelo determinista de base + modelo de residuos (boosting) + ensamble**, puede ser más efectiva y robusta que usar únicamente modelos de *deep learning*.



En resumen, los resultados cuantitativos y las gráficas de comparación respaldan la elección del **Ensamble Híbrido Regresión Armónica + XGBoost** como modelo final del proyecto. Este modelo no solo minimiza el error de pronóstico, sino que además genera predicciones físicamente plausibles para la primera semana de 1991, respetando el patrón estacional del clima de Melbourne.

## 8. Conclusiones

En este proyecto se construyeron y compararon varios modelos de pronóstico para la temperatura mínima diaria en Melbourne usando solo la serie histórica 1981–1990. El análisis exploratorio mostró que la serie está dominada por una **estacionalidad anual muy fuerte** y que no existe una tendencia clara de calentamiento o enfriamiento en ese periodo.

La **Regresión Armónica con términos de Fourier** demostró que un modelo estadístico simple, que combina una tendencia lineal con componentes senoidales anuales, es capaz de capturar gran parte de la dinámica de la serie con buen desempeño ( $\text{RMSE} \approx 2.53 \text{ }^{\circ}\text{C}$ ). Los modelos de **LSTM** y **XGBoost** también ofrecieron resultados competitivos, especialmente en la captura de la variación de corto plazo, pero por sí solos no superaron de forma contundente al modelo armónico.

El mejor resultado se obtuvo con un **ensamble híbrido** que combina Regresión Armónica (30 %) y XGBoost (70 %). Este modelo alcanzó los menores errores ( $\text{RMSE} \approx 2.23 \text{ }^{\circ}\text{C}$ ,  $\text{MAE} \approx 1.75 \text{ }^{\circ}\text{C}$ ) y generó pronósticos visualmente suaves y físicamente plausibles, especialmente en el pronóstico fuera de muestra para la primera semana de 1991 (mínimas entre 12  $^{\circ}\text{C}$  y 15  $^{\circ}\text{C}$ , coherentes con el verano austral).

De cara al futuro, este trabajo puede ampliarse en varias direcciones:

- incorporar **variables exógenas** (humedad, precipitación, presión, viento) para mejorar la capacidad del modelo de capturar eventos atípicos;
- utilizar esquemas de **validación temporal más robustos** (por ejemplo, *walk-forward validation*) y búsquedas sistemáticas de hiperparámetros;
- explorar **arquitecturas alternativas** de deep learning (GRU, TCN, Transformers para series de tiempo) y ensambles más sofisticados donde los modelos aprendan a corregirse mutuamente sobre los residuos.

En síntesis, el proyecto muestra que, para series climáticas con datos limitados y fuerte estacionalidad, una estrategia que combine **modelos deterministas interpretables** con **modelos de machine learning** puede ser más efectiva y robusta que el uso aislado de modelos profundos.

## 9. Referencias:

Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). ACM. <https://doi.org/10.1145/2939672.2939785>

Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). OTexts. <https://otexts.com/fpp3/>

Hyndman, R. J. (2010, September 29). Forecasting with long seasonal periods. *Hyndman Blog*. <https://robjhyndman.com/hyndman/longseasonality/>

## 10. Anexos:

### Anexo de código

Todo el código utilizado para el análisis, preprocesamiento, entrenamiento de modelos y generación de pronósticos se encuentra documentado en el **notebook ProyectoFinal.ipynb**, el cual se adjunta como **anexo técnico** al presente reporte. Este notebook permite **reproducir completamente** los resultados mostrados en las figuras y tablas del documento.